

Теореми про збіжність градієнтних методів

Теореми про збіжність сформулюємо для методу найшвидшого спуску. Вони будуть справедливі і для інших градієнтних методів.

Теорема 1 (умови 1-3). Нехай виконані умови:


- 1) $f(x) \in C^1(E^n)$;
- 2) $f(x)$ обмежена знизу: $\inf f(x) = f_* > -\infty, x \in E^n$;
- 3) градієнт функції $f(x)$ задовольняє умову Ліпшиця:

$$\|f'(x') - f'(x'')\| \leq L\|x' - x''\|, \quad \forall x', x'' \in E^n,$$

$L > 0$ – константа Ліпшиця.

Тоді послідовність $\{x^{(k)}\}_0^\infty$, яку побудовано за методом (2),(3) є такою, що $\|f'(x^{(k)})\| \rightarrow 0$ при $k \rightarrow \infty$ для будь-якого початкового наближення $x^{(0)}$.

Доведення: На промені $\{x : x = x^{(k)} - \alpha f'(x^{(k)}), \alpha > 0\}$ візьмемо довільну точку x .



За теоремою про середнє для будь-якої початкової точки $x^{(0)}$:

$$f(x) - f(x^{(k)}) = (f'(\bar{x}^{(k)}), x - x^{(k)}) =$$

{точка $\bar{x}^{(k)} \in [x^{(k)}, x]$ і може бути представлена як

$$\bar{x}^{(k)} = x^{(k)} + \theta(x - x^{(k)}), \quad 0 \leq \theta \leq 1\}$$

$$= (f'(\bar{x}^{(k)}) + f'(x^{(k)}) - f'(x^{(k)}), x - x^{(k)}) =$$

$$= (f'(x^{(k)}), x - x^{(k)}) + (f'(\bar{x}^{(k)}) - f'(x^{(k)}), x - x^{(k)}) \leq$$

{застосуємо до другого доданку нерівність Коші-Буняковського: $|(a, b)| \leq \|a\| \cdot \|b\|$ }

$$\leq (f'(x^{(k)}), x - x^{(k)}) + \|f'(\bar{x}^{(k)}) - f'(x^{(k)})\| \cdot \|x - x^{(k)}\| \leq$$

{за умовою Ліпшиця}

$$\leq (f'(x^{(k)}), x - x^{(k)}) + L\|\bar{x}^{(k)} - x^{(k)}\| \cdot \|x - x^{(k)}\| \leq$$

{виберемо таку точку x , щоб $\theta = 1$ }

$$\leq (f'(x^{(k)}), x - x^{(k)}) + L\|x - x^{(k)}\|^2 =$$

{за ітераційною формулою $x - x^{(k)} = -\alpha f'(x^{(k)})$ }

$$= -\alpha \left\| f'(x^{(k)}) \right\|^2 + L\alpha^2 \left\| f'(x^{(k)}) \right\|^2.$$

Позначимо функцію відносно α як

$$\phi(\alpha) = -\alpha \left\| f'(x^{(k)}) \right\|^2 + L\alpha^2 \left\| f'(x^{(k)}) \right\|^2.$$

Функція $\phi(\alpha)$ є квадратичною і, отже, опуклою. Знайдемо мінімум функції $\phi(\alpha)$ класичним методом: $\phi'(\alpha) = 0$.

$$2L\alpha \left\| f'(x^{(k)}) \right\|^2 - \left\| f'(x^{(k)}) \right\|^2 = 0,$$

$$\alpha_{min} = \frac{1}{2L}, \quad \phi(\alpha_{min}) = \frac{\left(\left\| f'(x^{(k)}) \right\|^2 - 2 \left\| f'(x^{(k)}) \right\|^2 \right)}{4L} = -\frac{\left\| f'(x^{(k)}) \right\|^2}{4L}.$$

Отже,

$$x^{(k+1)} = x^{(k)} - \alpha_{min} f'(x^{(k)}),$$

$$f(x^{(k+1)}) - f(x^{(k)}) \leq f(x) - f(x^{(k)}) \leq -\phi(\alpha_{min}) = -\frac{\left\| f'(x^{(k)}) \right\|^2}{4L}.$$

За самою побудовою методу, виконується умова монотонності:

$$f(x^{(k+1)}) < f(x^{(k)}), \quad \lim_{k \rightarrow \infty} [f(x^{(k+1)}) - f(x^{(k)})] = 0,$$

$$\left\| f'(x^{(k)}) \right\|^2 \leq -4L [f(x^{(k+1)}) - f(x^{(k)})], \quad \left\| f'(x^{(k)}) \right\|^2 \rightarrow 0 \text{ при } k \rightarrow \infty. \quad \square$$

Теорема 1 (з умовами 1-3) встановлює збіжність за функцією до нижньої межі.

Теорема 1 (умови 1-4). Нехай виконані умови 1)-3) та

4) множина $M(x^{(0)}) = \{ x \in E^n : f(x) \leq f(x^{(0)}) \}$ – обмежена,

тоді

$$\lim_{k \rightarrow \infty} \rho(x^{(k)}, S_*) = 0,$$

де $S_* = \{ x \in M(x^{(0)}) : f'(x) = 0 \}$ – множина стаціонарних точок функції $f(x)$ на $M(x^{(0)})$, $\rho(x^{(k)}, S_*)$ – відстань від точки $x^{(k)}$ до множини S_* стаціонарних точок функції $f(x)$.

У випадку виконання умов теореми 1 (з умовами 1-4) метод найшвидшого спуску забезпечує тільки збіжність до множини стаціонарних точок S_* , але при таких умовах неможливо оцінити швидкість збіжності і стверджувати збіжність до множини точок мінімуму X_* .

Теорема 2. Якщо виконуються умови (1)-(4) теореми 1 і, крім того, функція $f(x)$ опукла на E^n , тоді:

- 1) послідовність $\{x^{(k)}\}_0^\infty$ є мінімізуючою,
- 2) послідовність $\{x^{(k)}\}_0^\infty$ збігається до множини точок мінімуму функції $f(x)$,
- 3) має місце оцінка за функцію

$$f(x^{(k)}) - f(x_*) \leq \frac{4D^2L}{k}, \quad k = 1, 2, \dots$$

Тут D – діаметр множини $M(x^{(0)})$:

$$D = \max \|x' - x''\|, \quad x', x'' \in M(x^{(0)}).$$

Теорема 2 стверджує про збіжність за змінною і дає оцінку швидкості збіжності за функцією. Оцінка швидкості збіжності за змінною можлива лише при більш жорстких припущеннях щодо функції f .

Теорема 3. Нехай функція $f(x) \in C^2(E^n)$ і її матриця Гессе задовольняє умову:

$$m\|z\|^2 \leq (f''(x)z, z) \leq M\|z\|^2, \quad 0 < m \leq M, \quad \forall x, z \in E^n, \quad (8)$$

тоді послідовність $\{x^{(k)}\}_0^\infty$, побудована за формулами (2), (3) збігається до точки x_* зі швидкістю геометричної прогресії зі знаменником $q = \frac{M-m}{M+m}$ (лінійно) незалежно від початкового наближення та справедлива така оцінка

$$\|x^{(k+1)} - x_*\| \leq \frac{M-m}{M+m} \|x^{(k)} - x_*\|. \quad (9)$$

Функція $f(x)$, яка задовольняє умову (8), називається **сильно опуклою функцією**. Числа m та M – це найменше та найбільше власні числа матриці других похідних $f''(x)$.

Геометричний сенс градієнтних методів

1. Градієнт $f'(x^{(k)})$ – перпендикулярний в точці $x^{(k)}$ лінії рівня $\Gamma_k = \{x : f(x) = f(x^{(k)})\}$ (рис. 1). Це властивість є справедлива для всіх градієнтних методів.




Рис. 1

2. Для методу **найшвидшого спуску** два послідовно знайдених напрямку спуску $(-f'(x^{(k)}))$ та $(-f'(x^{(k+1)}))$ є взаємно ортогональними (рис. 2).




Рис. 2

3. Градієнтний метод (відмінний від методу найшвидшого спуску) генерує послідовність точок $\{x^{(k)}\}_0^\infty$, які утворюють зигзагоподібну траєкторію $x^{(0)}, x^{(1)}, x^{(2)}, \dots, x^{(k)}$ (рис. 3).





Рис. 3

Переваги градієнтних методів такі:

- 1) досить прості в реалізації,
- 2) вимоги до цільової функції не є дуже жорсткими (функція $f(x)$ повинна бути диференційовна в E^n),
- 3) є основою для розробки інших більш ефективних методів оптимізації,
- 4) часто використовуються на початковому етапі розв'язання задачі. Їх застосування доцільне у випадку, коли початкове наближення знаходиться далеко від точки мінімуму цільової функції, а кроки уздовж антиградієнту дозволяють значно зменшити значення цільової функції. Потім застосовуються інші більш ефективні методи оптимізації.

Недоліки градієнтних методів такі:

- 1) невисока швидкість збіжності (тільки лінійна) при таких жорстких вимогах до цільової функції як двічі неперервно-диференційовність і сильна опуклість (теорема 3);
- 2) повільна збіжність для функцій, в яких поверхні (лінії рівня) сильно витягнуті та функція має так званий «яружний» характер (рис. 4).



Вплив кривизни ліній рівня на швидкість збіжності

Нехай

$$f(x) = (A(x - x_*), x - x_*),$$

де A – симетрична додатно визначена матриця.

Функція $f(x) \in C^2(E^n)$ та є сильно опукла, тобто

$$m\|z\|^2 \leq (Az, z) \leq M\|z\|^2, \quad \forall z \in E^n,$$

m та M є найменше і найбільше власні числа матриці A .

Припустимо, що $m = M$, тоді $f(x) = M\|x - x_*\|^2$. Лінії рівня такої цільової функції є концентричними колами.

Чим більше будуть відрізнятися між собою m та M , тим більше будуть витягнутими будуть лінії рівня.

Чим більше витягнуті лінії рівня, тим гірше буде збігатися градієнтний метод. Це також видно з оцінки швидкості збіжності:

$$\|x^{(k+1)} - x_*\| \leq \frac{M - m}{M + m} \|x^{(k)} - x_*\|.$$

Матриця $f''(x)$ других похідних буде добре обумовленою, якщо m та M мало відрізняються один від одного і погано обумовленою, якщо $m \ll M$.

Якщо числа m та M мало відрізняються між собою, тобто матриця $f''(x)$ добре обумовлена, то число q близько до нуля і, отже, збіжність краще. Якщо $m/M \ll 1$, то q близько до 1 і метод збігається повільніше.

Геометричне тлумачення цього факту: зі зменшенням відношення m/M лінії рівня стають більш витягнутими та напрямок спуску (антиградієнт) у більшості точок істотно відхиляється від напрямку на точку мінімуму.

Шляхи прискорення збіжності для функцій з витягнутими лініями рівня:

1) масштабування, тобто перехід до іншої функції заміною змінних.

Наприклад: $f(x) = x_1^2 + 25x_2^2$, зробимо заміну змінних $\xi_1 = x_1$, $\xi_2 = 5x_2$.

$g(\xi) = \xi_1^2 + \xi_2^2$ (рис. 5).

x_2

ξ_2




Рис. 5.

2) створення методів, які з геометричних міркувань, враховують кривизну ліній рівня. В основному це евристичні методи (не доведена збіжність в загальному випадку). Наприклад, r -алгоритми Шора.

3) створення методів, які враховує інформацію про кривизну ліній рівня з використанням матриці других похідних (метод Ньютона).